



**ÉCOLE MAROCAINE DES
SCIENCES DE L'INGÉNIEUR**

Membre de
HONORIS UNITED UNIVERSITIES



MODÈLES STATISTIQUES

ÉCOLE
MAROCAINE
DES **SCIENCES**
DE L'INGÉNIEUR

Filière : **Ingénierie Informatique et Réseaux**

SEMESTRE : 6

Année : 2025-2026

Les Séries Temporelles et le Modèle ARIMA

Qu'est-ce qu'une série temporelle ?

Définition

Une **série temporelle** est une suite de valeurs observées dans le temps et classées dans l'ordre chronologique.

Exemples :

- les ventes mensuelles d'un produit ;
- la température mesurée chaque jour ;
- le trafic d'un site web par heure ;
- le cours journalier d'une action.

Objectif

Analyser le passé pour mieux **comprendre l'évolution** d'un phénomène et **prévoir** ses valeurs futures.

Les principales composantes d'une série

Dans une série temporelle, on cherche souvent à repérer :

- **la tendance** : évolution générale à la hausse ou à la baisse ;
- **la saisonnalité** : répétition régulière d'un phénomène ;
- **les fluctuations aléatoires** : variations irrégulières ou imprévues.

Exemple

Si les ventes augmentent globalement mais montent davantage chaque été, alors la série contient à la fois une **tendance** et une **saisonnalité**.

Qu'est-ce qu'une série stationnaire ?

Une série temporelle est dite **stationnaire** lorsqu'elle reste globalement stable dans le temps.

En pratique :

- sa moyenne ne change pas fortement ;
- sa variance reste à peu près constante ;
- sa dépendance au passé reste stable.

À retenir

Une série stationnaire ne présente pas de forte tendance durable et ses fluctuations restent autour d'un niveau relativement constant.

Pourquoi la stationnarité est-elle importante ?

Le modèle **ARIMA** s'appuie sur l'idée que la relation entre le présent et le passé reste stable dans le temps.

- Si la série présente une forte tendance, les corrélations peuvent être trompeuses.
- Si la variance change beaucoup, les prévisions deviennent moins fiables.
- Une série stationnaire est donc plus simple à modéliser correctement.

Idée clé

Avant d'ajuster un modèle ARIMA, on cherche généralement à rendre la série **suffisamment stationnaire**.

Comment rendre une série stationnaire ?

Si la série n'est pas stationnaire, on peut utiliser plusieurs transformations :

- **la différenciation** :

$$Y_t = X_t - X_{t-1}$$

- **la transformation logarithmique** : utile si la variance augmente avec le niveau de la série ;
- **la décomposition** : pour retirer une tendance ou une saisonnalité.

Remarque

Dans de nombreux cas, une seule différenciation suffit : on prend alors $d = 1$.

Comprendre la différenciation

Idée

La différenciation ne regarde plus les niveaux de la série, mais **les variations entre deux instants successifs**.

Exemple simple :

- Série initiale : 100, 109, 120, 130
- Série différenciée : 9, 11, 10

Ainsi, une série qui augmente régulièrement peut devenir plus stable après différenciation.

Le modèle ARIMA

Introduction

Le modèle **ARIMA** est un modèle statistique utilisé pour **analyser** et **prévoir** l'évolution d'une série temporelle.

Il exploite l'information contenue dans le passé de la série afin d'obtenir un modèle de prévision adapté.

Idée clé

ARIMA tient compte des **valeurs passées**, de la **différenciation** et des **erreurs passées**.

Structure du modèle ARIMA

Le modèle **ARIMA** (*AutoRegressive Integrated Moving Average*) combine trois composantes :

- **AR** (*AutoRegressive*) : dépendance aux valeurs passées ;
- **I** (*Integrated*) : différenciation pour rendre la série stationnaire ;
- **MA** (*Moving Average*) : dépendance aux erreurs passées.

Notation

$$ARIMA(p, d, q)$$

Interprétation de p , d et q

Dans le modèle $\text{ARIMA}(p, d, q)$:

- p : nombre de valeurs passées qui influencent encore la valeur actuelle ;
- d : nombre de différenciations nécessaires pour stationnariser la série ;
- q : nombre d'erreurs passées prises en compte dans le modèle.

Exemples

- Si $p = 1$, la valeur actuelle dépend surtout de la dernière valeur passée.
- Si $p = 2$, la série garde la mémoire de ses deux dernières valeurs.
- Si $d = 1$, on a différencié une seule fois la série.
- Si $q = 1$, la valeur actuelle dépend aussi de la dernière erreur de prévision.

Forme mathématique générale d'ARIMA

Notations :

- X_t : valeur observée à la date t ;
- $Y_t = \nabla^d X_t$: série différenciée d fois ;
- ϕ_i : coefficients de la partie AR ;
- θ_j : coefficients de la partie MA ;
- ε_t : bruit blanc.

Écriture du modèle

$$\underbrace{Y_t}_I = \underbrace{\sum_{i=1}^p \phi_i Y_{t-i}}_{\text{AR}} + \underbrace{\sum_{j=1}^q \theta_j \varepsilon_{t-j}}_{\text{MA}}$$

Idée

Le modèle relie la série actuelle à son **passé** et à ses **erreurs passées**.

Données de départ

On considère les ventes mensuelles d'un produit durant l'année 2023.

Mois	Ventes X_t
Jan 2023	380
Fév 2023	400
Mar 2023	390
Avr 2023	410
Mai 2023	430
Juin 2023	450
Juil 2023	440
Août 2023	460
Sep 2023	470
Oct 2023	480
Nov 2023	500
Déc 2023	520

On observe déjà une **tendance globale croissante**.

Visualisation de la série

- La courbe des ventes montre une hausse globale.
- La série brute n'est donc pas idéale pour un ARIMA sans transformation préalable.




Figure – Évolution des ventes mensuelles en 2023.

Stationnarisation par différenciation

Pour réduire la tendance, on calcule :

$$Y_t = X_t - X_{t-1}$$

Mois	Différence Y_t
Fév 2023	$400 - 380 = 20$
Mar 2023	$390 - 400 = -10$
Avr 2023	$410 - 390 = 20$
Mai 2023	$430 - 410 = 20$
Juin 2023	$450 - 430 = 20$
Juil 2023	$440 - 450 = -10$
Août 2023	$460 - 440 = 20$
Sep 2023	$470 - 460 = 10$
Oct 2023	$480 - 470 = 10$
Nov 2023	$500 - 480 = 20$
Déc 2023	$520 - 500 = 20$

Interprétation après différenciation

Après différenciation, la série :

- oscille autour d'un niveau plus stable ;
- ne présente plus de tendance nette ;
- semble avoir une variabilité relativement constante.

Conclusion

On considère ici que la série différenciée est **stationnaire au sens faible**. On pourra donc essayer un modèle avec $d = 1$.

Comment choisir p et q ?

Plusieurs outils peuvent être utilisés :

- l'analyse des graphes **ACF** et **PACF** ;
- les critères d'information **AIC** et **BIC** ;
- les tests de stationnarité, comme **Dickey-Fuller**.

Dans ce cours, nous utilisons surtout l'analyse **ACF/PACF** pour proposer un modèle candidat.

Qu'est-ce qu'un lag ?

Un **lag** correspond à un **décalage dans le temps**.

Exemples :

- lag 1 : une période avant ;
- lag 2 : deux périodes avant ;
- lag 3 : trois périodes avant.

Exemple mensuel

Si l'on est en décembre :

- novembre correspond au **lag 1** ;
- octobre correspond au **lag 2** ;
- septembre correspond au **lag 3**.

À retenir

Le lag indique **à quelle distance dans le passé on regarde**.

Que mesurent les fonctions ACF et PACF ?


- **ACF** (*Autocorrelation Function*) : mesure la corrélation globale entre la série stationnaire Y_t et ses **valeurs passées**.
- **PACF** (*Partial Autocorrelation Function*) : mesure la corrélation **directe** entre Y_t et une valeur passée, après avoir retiré l'effet des lags intermédiaires.

Rôle dans ARIMA

- la **PACF** aide surtout à proposer une valeur de p ;
- l'**ACF** aide surtout à proposer une valeur de q .

Interprétation ACF/PACF (exemple)

Pour notre exemple :



Comment lire les graphes ACF et PACF ?

Règle pratique

- Si la **PACF** présente une **coupure nette** après le lag p , cela **suggère** un modèle $AR(p)$.
- Si l'**ACF** présente une **coupure nette** après le lag q , cela **suggère** un modèle $MA(q)$.

Que signifie “coupure nette” ?

- on observe un ou plusieurs **pics significatifs** au début ;
- puis les autres pics deviennent faibles ou non significatifs.

Exemple

Si la PACF a un pic important au lag 1 puis presque plus rien après, on peut **essayer** un modèle $AR(1)$.

Si l'ACF a un pic important au lag 1 puis presque plus rien après, on peut **essayer** un modèle $MA(1)$.

Application à notre exemple

Dans cet exemple illustratif :

- l'ACF montre un pic significatif au lag 1 ;
- la PACF montre également un pic significatif au lag 1 ;
- la série a été différenciée une fois.

Modèle candidat

On peut donc **essayer** le modèle :

$$ARIMA(1, 1, 1)$$

Important

Les graphes ACF/PACF donnent des indices pour proposer un **modèle candidat**, mais ils ne permettent pas toujours d'identifier un modèle unique et définitif.

Écriture du modèle ARIMA(1,1,1)

Forme générale :

$$Y_t = \sum_{i=1}^p \phi_i Y_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

Pour $p = 1$, $d = 1$ et $q = 1$, on écrit :

$$Y_t = X_t - X_{t-1}$$

$$Y_t = \phi_1 Y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

- la variation actuelle dépend de la variation passée ;
- elle dépend aussi de l'erreur actuelle et de l'erreur passée.

Entraînement du modèle

Une fois le modèle choisi, on estime ses paramètres à partir des données.

- On ajuste ici un modèle ARIMA(1,1,1) sur les 12 observations.
- L'algorithme estime les paramètres ϕ_1 et θ_1 .
- Le but est de minimiser l'erreur de prévision.

Résultat

Après estimation, on obtient un modèle calibré que l'on peut utiliser pour prévoir les valeurs futures.

Exemple numérique de prévision

Supposons, pour l'exemple :

- $\phi_1 = 0,8$,
- $\theta_1 = 0,6$,
- $\varepsilon_{12} = -4$,
- $\varepsilon_t = 0$ pour $t \geq 13$.

La dernière observation est :

$$X_{12} = 520, \quad Y_{12} = X_{12} - X_{11} = 20$$

Alors :

$$\hat{Y}_{13} = 0,8 \times 20 + 0,6 \times (-4) = 13,6$$

$$\hat{Y}_{14} = 0,8 \times 13,6 \approx 10,88$$

$$\hat{Y}_{15} = 0,8 \times 10,88 \approx 8,70$$

Reconstruction des valeurs prévues

À partir des différences prévues, on reconstitue la série initiale :

$$\hat{X}_{13} = X_{12} + \hat{Y}_{13} = 520 + 13,6 = 533,6$$

$$\hat{X}_{14} = \hat{X}_{13} + \hat{Y}_{14} = 533,6 + 10,88 = 544,48$$

$$\hat{X}_{15} = \hat{X}_{14} + \hat{Y}_{15} = 544,48 + 8,70 \approx 553,18$$

Exemple de prévisions

[533,6, 544,48, 553,18, 560,15, 565,72, 570,17]

Visualisation des prévisions




Figure – Prévision ARIMA(1,1,1) sur 6 mois.

Conclusion

- Une série temporelle est une suite de données observées dans le temps.
- Avant d'utiliser ARIMA, on cherche à rendre la série **stationnaire**.
- Le modèle **ARIMA**(p, d, q) combine :
 - une partie **AR** : dépendance aux valeurs passées ;
 - une partie **I** : différenciation ;
 - une partie **MA** : dépendance aux erreurs passées.
- Les graphes **ACF/PACF** aident à choisir un modèle candidat.
- Dans notre exemple, **ARIMA(1,1,1)** constitue un choix simple et pédagogique.